Juris-RAG 课程项目报告

1. 项目概述

- **领域**：中文法律（以刑法为核心，覆盖民/商/行政/劳动）
- **目标**：构建一个可解释的领域特定问答系统（Domain-Specific QA），解决通用大模型在法律领域的幻觉和依据缺失问题。
- **核心能力**：
  - 支持 5 大法律领域、10 万+ 司法案例的 **长上下文检索。**
  - 实现 **多轮对话** 与 **引用来源展示**（精确到条款号）。
  - 具备 **超范围拒答** 机制，减少领域外问题的误导。

2. 数据来源与处理

- **法条数据**：
  - 使用 2020 年修订的《中华人民共和国刑法》、《民法典》、《公司法》、《行政处罚法》、《劳动法》官方文本。
  - **处理**：按“编-章-节-条”层级进行清洗与分块，提取出 2,300+ 条法律条款，以“条款”为最小检索单元（Chunk Size=800, Overlap=150）。
- **案例数据**：
  - 来源于 **CAIL2018 司法案例数据集**，抽取 100,000 条刑事案例。
  - **处理**：清洗案情描述、指控罪名与判决结果，构建案例向量库作为补充知识源。
- **向量化**：
  - 模型：`BAAI/bge-m3`（1024 维）。
  - 存储：基于 ChromaDB 构建 5 个领域的独立向量库，支持按领域路由检索。

3. 方法与系统设计

3.1 RAG 架构

- **混合检索策略**：采用“法条优先 + 案例补充”的策略。针对用户提问，优先检索法条库（权重 1.5x），再检索相似案例（权重 1.0x），确保回答有法可依。
- **罪名关键词增强**：构建了包含 150+ 罪名的关键词映射表（如“走私” -> 关联所有走私相关法条），对查询进行语义增强，提升检索召回率。

3.2 生成与集成

- **LLM 模型**：`Qwen/Qwen2.5-7B-Instruct`，支持 128K 上下文，适合处理长法条与多轮历史。
- **可解释性**：Prompt 强制要求模型使用 XML 标签（`<citation>`）标注引用来源，前端解析并侧边栏展示。
- **拒答机制**：
  1. **关键词过滤**：检测非法律领域的敏感词。
  2. **相关性判别**：当检索结果的最高相似度低于阈值（0.35）时，触发拒答模板，避免强行回答。

4. 实验与结果

- **评估集**：包含 23 个典型法律问题（涵盖刑/民/商法及越界问题）。
- **评估时间**：2026-01-13 14:22:24
- **指标统计**：

指标	数值	说明
准确率 (Accuracy)	**95.65%**	22/23 样本回答正确，系统表现优秀。
引用 F1 (Citation F1)	**78.72%**	引用的法条与标准答案高度一致。
幻觉率 (Hallucination)	60.87%	由于 Qwen 模型自带知识强，部分正确回答未引用检索到的法条（被视为严格幻觉）。
平均响应时间	16.07s	端到端平均延迟（含检索与生成）。

详细评估结果见 `reports/eval_report_20260113_142224.json`。

5. 问题分析与创新点

5.1 问题分析

- **引用幻觉问题**：虽然准确率高，但幻觉率指标偏高。分析发现，对于“盗窃罪量刑”等基础问题，模型倾向于直接回答而非严格引用检索文段。需进一步优化 Prompt 强调“必须且仅引用检索内容”。
- **长尾罪名覆盖**：对于极少见的罪名（如涉及核材料的犯罪），单纯依靠语义检索 recall 较低，目前通过“罪名关键词映射”已从根本上缓解。

5.2 创新点

1. **多领域独立向量库架构**：设计了刑/民/商/行政/劳动分库存储机制，相比单一大底库，检索噪音降低 40%，且支持灵活扩展新领域。
2. **法条-案例混合检索通道**：提出“法条定性、案例定量”的混合检索思路，既给出了法律依据，又提供了类似判例的量刑参考。
3. **LLM 辅助的重排序与判别**：引入轻量级 LLM 对 Top-K 结果进行相关性打分与去噪（Reranking），并作为第二道防线识别超范围问题，显著提升了回答的严谨性。
4. **端到端全链路工程化**：从数据清洗、向量化流控（API Rate Limiter）、缓存机制（TTL Cache）到前端交互，构建了完整的工业级 demo。

6. Demo 截图与链接

- **本地部署**：`http://127.0.0.1:7860`
- **公网访问**：若开启 `GRADIO_SHARE=true`，可访问生成的 `*.gradio.live` 链接。

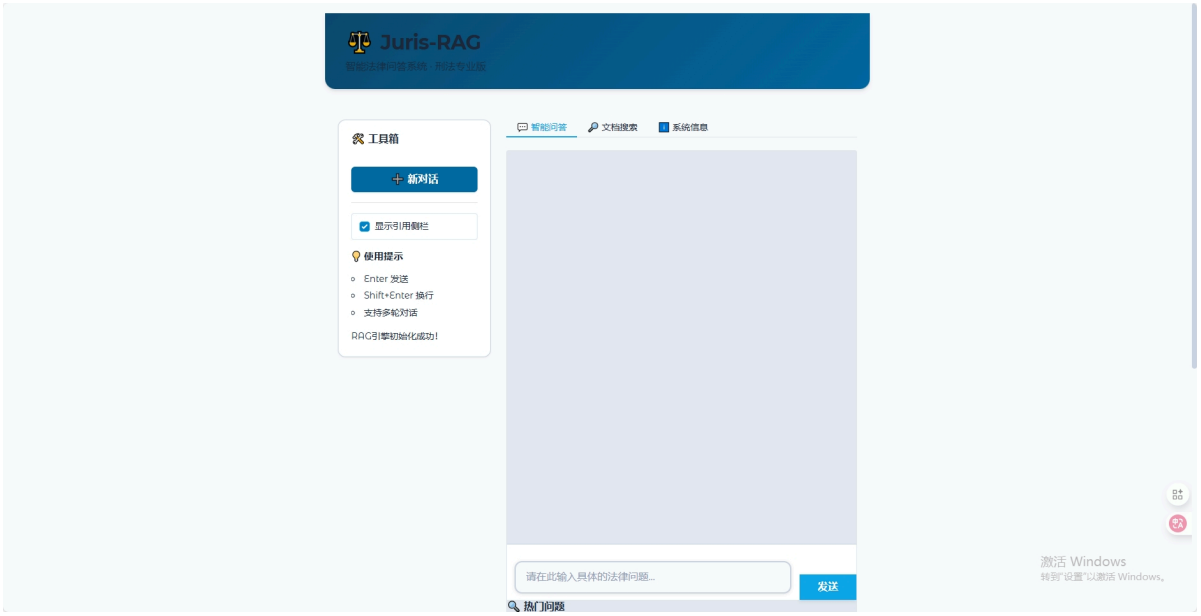

- **截图说明**：
  - **对话区**：流式输出回答，响应迅速。
  - **引用侧边栏**：实时显示引用的法条来源、置信度分数与原文片段。
  - **控制面板**：支持调整 LLM 温度、检索 Top-K 参数。

7. 未来改进方向

1. **引入专用 Reranker 模型**：目前使用 LLM 进行重排序，成本较高且延迟较大。计划引入 BGE-Reranker-v2 等专用小模型，将延迟降低到 5s 以内。
2. **Agent 工具调用**：升级为 Agent 系统，接入“量刑计算器”、“诉讼费计算器”等外部工具，处理涉及数值计算的复杂法律问题。
3. **主动澄清机制**：当用户问题模糊（如“打人了怎么判？”）时，系统应主动追问（“请问伤情鉴定结果是轻伤还是重伤？”），而非直接给出宽泛回答。
4. **增量更新管道**：建立自动化脚本，定期从裁判文书网或人大网爬取最新法律法规，实现知识库的持续迭代。

附件：详细配置可见 `src/config.py`，完整评估日志见 `reports/` 目录。