AI驱动的智能软件开发助手项目报告

项目名称: LLM驱动的智能代码生成与调试系统
学号/姓名: SX2516029-吴东东

目录

项目概述

1.1 项目背景与动机

问题: 传统软件开发流程中，从需求理解到代码实现需要大量人工工作，包括:

- 需求分析与设计
- 代码编写与重构
- 测试用例设计
- Bug修复与迭代优化

解决方案: 构建一个AI驱动的智能软件开发助手(Software Engineering Agent)，利用大规模预训练代码语言模型(Code-LLM)自动化完成上述工作流程。

1.2 项目目标

1. **需求理解**: 自动分析用户需求，拆解为可执行的子任务
2. **代码生成**: 基于任务描述自动生成规范的Python代码
3. **自动化测试**: 根据需求自动设计和生成pytest测试用例
4. **智能调试**: 基于测试失败信息自动诊断和修复代码
5. **代码反思**: 集成反思机制，评估代码质量并给出改进建议
6. **整体评估**: 在HumanEval基准上进行系统评估

1.3 项目成果

✅ **完整的工作流系统** - 从需求到代码再到测试和调试的端到端流程
✅ **多模型支持** - 支持Qwen2.5-Coder、DeepSeek-Coder等代码专用LLM
✅ **反思机制** - 集成代码质量评估和迭代优化
✅ **基准测试** - 集成HumanEval评估脚本并已生成样本

✅ **CLI工具** - 提供命令行接口

技术架构

2.1 系统整体架构

系统遵循**模块化设计**理念，采用**顺序处理 + 反馈循环**的架构模式。每个阶段独立但相互关联，通过统一的数据结构进行交互。

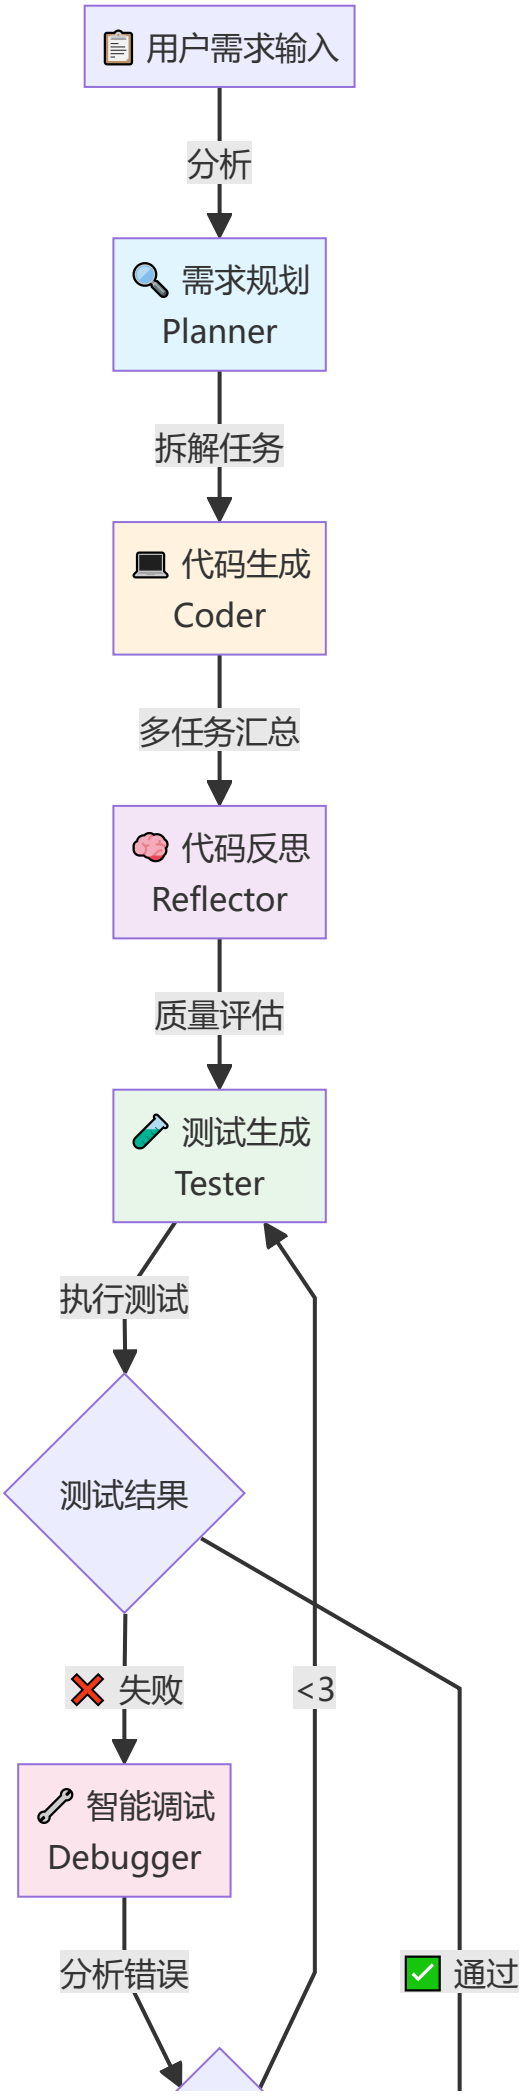
用户需求输入
分析
需求规划
Planner
拆解任务
代码生成
Coder
多任务汇总
代码反思
Reflector
质量评估
测试生成
Tester
执行测试
测试结果
失败
<3
智能调试
Debugger
分析错误
通过

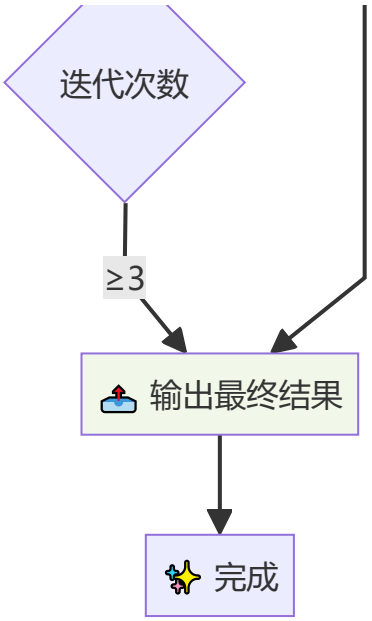

2.2 核心模块设计

各模块功能对照表

📦 模块	🎯 功能描述	📥 输入	📤 输出
planner.py	需求分析与任务拆解	需求文本	任务列表、复杂度评级
coder.py	多任务代码生成	需求、任务描述	规范化Python代码
tester.py	测试生成与执行	代码、需求	pytest用例、测试结果
debugger.py	错误诊断与修复	失败信息	修复后的代码
reflector.py	代码质量评估	代码、需求	质量评分、建议
llm_client.py	LLM调用封装	Prompt、模型	LLM响应
prompt_manager.py	提示词模板管理	模板名、参数	格式化Prompt
agent_loop.py	主工作流编排	用户需求	完整结果字典

模块交互流程

```
用户需求
  ↓
[Planner] 任务拆解 → {project_name, tasks[], complexity}
  ↓
[Coder] 增量生成 → {code, task_results[]}
  ↓
[Reflector] 质量评估 → {score, dimensions{}, suggestions[]}
  ↓
[Tester] 自动测试 → {passed, failed, error_summary}
  ↓
[Decision] 是否通过?
  ├─ 是 → 保存输出 ✅
  └─ 否 → [Debugger] 修复 → 重新测试 (max 3 轮)
  ↓
```

```
[Agent Loop] 汇总结果 → 文件输出
```

2.3 技术栈详解

核心依赖:

- **后端**: Python 3.8+ | Typer (CLI) | Pydantic (数据验证)
- **LLM**: Ollama (本地推理) | Qwen2.5-Coder 7B
- **测试**: pytest | human-eval
- **质量**: PEP8规范 | Type Hints | Docstring

数据交互: 模块通过统一的JSON结构交互，包含project_name、complexity、tasks[]、reflection{}、test_result{}、debug_history[]

核心功能实现

本章详细介绍系统的5大核心功能模块的设计与实现原理。

3.1 需求规划与任务拆解

功能描述

系统对用户需求进行智能分析，自动判断复杂度并拆解为可执行的子任务。

实现流程

步骤	操作	输出示例
1	需求理解	识别关键词、复杂度
2	复杂度评级	`简单` / `中等` / `复杂`
3	任务拆解	分解为1-N个子任务
4	输出规划	JSON格式的任务清单

规划输出示例

swebench_predictions.jsonl U | agent_loop.py M | planner.py M | result.json U

wddCodeAgent > {} result.json > [ ] tasks

```json
{
    "project_name": "sorting_algorithms",
    "description": "实现快速排序、冒泡排序和数组合并算法",
    "complexity": "简单",
    "should_split": false,
    "tasks": [
        {
            "id": 1,
            "name": "实现快速排序算法",
            "description": "实现快速排序算法，要求能够对整数数组进行排序。",
            "dependencies": [],
            "estimated_lines": 50
        },
        {
            "id": 2,
            "name": "实现冒泡排序算法",
            "description": "实现冒泡排序算法，要求能够对整数数组进行排序。",
            "dependencies": [],
            "estimated_lines": 30
        },
        {
            "id": 3,
            "name": "实现数组合并功能",
            "description": "实现一个函数，能够将两个已排序的整数数组合并成一个有序数组。",
            "dependencies": [],
            "estimated_lines": 20
        }
    ]
}
```

核心流程

通过 `PromptManager` 构建规划提示词 → `LLMClient` 调用模型 → JSON格式解析返回规划结果。

3.2 多任务代码生成 💻

```
============================================================
📋 [TASK 1/1] 实现数字距离检查函数
============================================================
[CODER] 生成代码...
[INFO] Loaded prompt: coder
[INFO] Loaded prompt: debugger
[INFO] Loaded prompt: planner
[INFO] Loaded prompt: reflector
[INFO] Loaded prompt: tester
[INFO] ✓ __init__.py (auto-generated) saved to results\generated_code\number_distance_checker\__init__.py
[INFO] ✓ main.py saved to results\generated_code\number_distance_checker\main.py
[INFO] 项目 'number_distance_checker' 已保存 2 个文件到 results\generated_code\number_distance_checker

[SUCCESS] 项目已保存 2 个文件
```

功能描述

对规划出的每个任务进行代码生成，并智能汇总为一个统一的项目文件。支持**增量生成**与**代码去重**。

核心特性

增量代码生成 🔗

```
Task 1: 基础实现
  ↓ 提供上下文
Task 2: 增量构建
  ↓ 继续提供上下文
Task 3: 最终完善
  ↓
完整代码
```

代码汇总与去重 ✨

- 遍历每个任务模块，提取函数定义
- 通过哈希集合检测并跳过重复定义
- 最终输出合并后的规范化代码文件

文件命名规范化:

- 输入: "快速排序算法" → `quick_sort_algorithm`
- 转换: snake_case, 全小写
- 验证: 符合Python模块命名规范

3.3 自动化测试生成 🧪

功能描述

根据需求和代码自动生成pytest测试用例，执行测试并解析结果。

1️⃣ **生成**: LLM 根据需求+代码生成 pytest 测试
2️⃣ **执行**: `pytest -v --tb=short` 运行测试
3️⃣ **解析**: 提取通过/失败统计与错误详情

测试结果示例

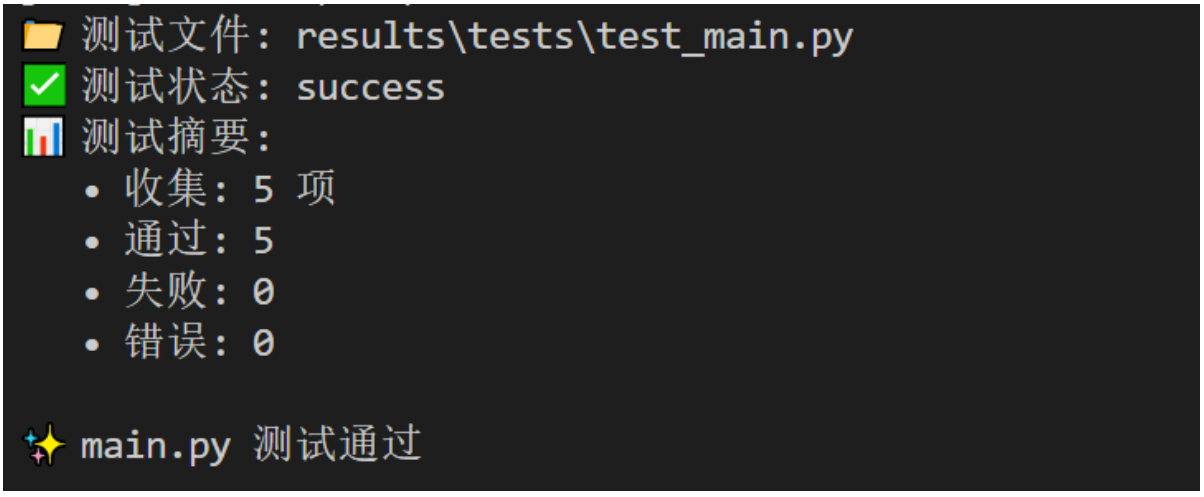

3.4 智能调试与修复 🔧

功能描述

当测试失败时，系统自动分析错误根因，调用LLM生成修复代码。支持多轮迭代调试。

调试流程

核心机制

1. 解析失败的测试与错误堆栈
2. 构建包含需求+当前代码+错误的调试提示词
3. 调用LLM生成修复方案
4. 应用修复后重新运行测试
5. 最多迭代3轮，通过则成功，失败则停止

例子如下：

```
/////////////////////////
🐛 [DEBUG] main.py 测试失败，开始调试...
/////////////////////////

📝 测试输出:
--------------------------------------------------
test_main.py::test_check_distance[-1--4-3-True] FAILED                   [ 75%]
test_main.py::test_check_distance[0-0-0-False] PASSED                    [100%]

================================= FAILURES =================================
_____________________ test_check_distance[5-3-2-True] _____________________

num1 = 5, num2 = 3, threshold = 2, expected = True

    @pytest.mark.parametrize('num1, num2, threshold, expected', [
        (5, 3, 2, True),  # 正常情况，距离小于阈值
        (5, 3, 1, False), # 边界情况，距离等于阈值
        (-1, -4, 3, True),# 正常情况，负数距离小于阈值
        (0, 0, 0, False), # 特殊情况，阈值为0
    ])
    def test_check_distance(num1, num2, threshold, expected):
>       assert check_distance(num1, num2, threshold) == expected
E       assert False == True
E        +  where False = check_distance(5, 3, 2)

test_main.py:18: AssertionError
                    test check distance[-1--4-3-True]
```

```
test_main.py:18: AssertionError
=========================== short test summary info ============================
FAILED test_main.py::test_check_distance[5-3-2-True] - assert False == True
FAILED test_main.py::test_check_distance[-1--4-3-True] - assert False == True
======================== 2 failed, 2 passed in 0.18s ========================
[DEBUGGER] 分析并修复代码...
[INFO] Loaded prompt: coder
[INFO] Loaded prompt: debugger
[INFO] Loaded prompt: planner
[INFO] Loaded prompt: reflector
[INFO] Loaded prompt: tester
[INFO] 发现 1 个bug，已修复

🔨 第 1 次修复完成
[TESTER] 生成测试用例...
[INFO] Loaded prompt: coder
[INFO] Loaded prompt: debugger
[INFO] Loaded prompt: planner
[INFO] Loaded prompt: reflector
[INFO] Loaded prompt: tester
[INFO] 测试文件已保存到: results\tests\test_main.py

🎉 main.py 所有测试通过！

============================================================
📊 测试结果汇总
============================================================

✅ 通过: 1/1 个文件
   ✓ main.py
```

3.5 代码质量反思机制 🧠

功能描述

代码生成后自动进行多维度质量评估，识别潜在问题并给出改进建议。支持4种反思模式。

评估维度

📌 维度	说明	满分

逻辑正确性	算法实现是否正确	10
代码风格	遵循PEP8规范	10
类型安全	类型注解完整度	8
文档完整性	docstring充分度	8
错误处理	异常处理覆盖度	7
效率优化	时间空间复杂度	7
可维护性	代码结构清晰度	10
	总分	**60**

反思模式对比

```
反思开销 vs 代码质量提升

disabled  ──────────────→  快速但质量低
light     ──────────────→  轻量反思
standard  ──────────────→  均衡方案 ⭐ 推荐
strict    ──────────────→  高质量但耗时
```

模式	耗时增长	质量提升	应用场景
`disabled`	0%	0%	原型、演示
`light`	+20%	+10%	研究、基准
`standard`	+40%	+20%	常规开发 ⭐
`strict`	+60%	+30%	生产环境

反思结果示例

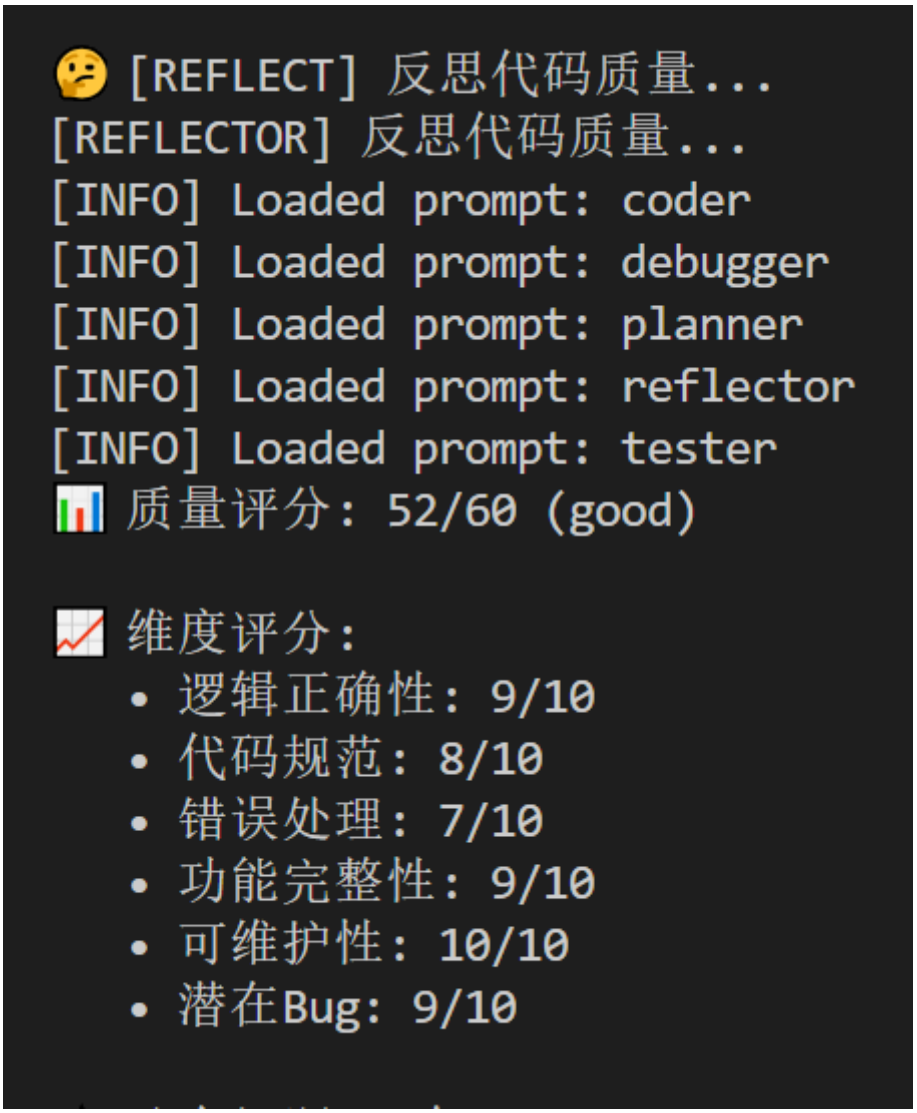

基准测试与性能评估

4.1 测试基准介绍

系统在权威基准上进行了评估：**HumanEval**。

基准	来源	规模	难度	场景	状态
HumanEval	OpenAI	164题	入门-中级	算法、数据结构	✅ 已评

4.2 HumanEval 基准评估

4.2.1 数据集与评估流程

数据集特性:

- 规模: 164个独立编程任务
- 难度: 入门级到中级（算法、字符串、数据结构等）
- 语言: Python
- 官方评测: 通过 `pass@1` 指标衡量

评估流程:

```
┌──────────────────────┐
| 1. 加载164个任务    |
└──────────┬───────────┘
           ↓
┌──────────────────────────────────────┐
| 2. 逐个调用Agent生成代码          |
|    (完整工作流: 规划→生成→测试→调试) |
└──────────┬───────────────────────────┘
           ↓
┌──────────────────────────────────────┐
| 3. 用官方test case评估            |
|    (pytest 执行，10秒超时)        |
└──────────┬───────────────────────────┘
           ↓
┌──────────────────┐
| 4. 计算pass@1    |
|    (通过率%)     |
└──────────────────┘
```

4.2.2 评估结果与分析

测评配置:

- 模型: Qwen2.5-Coder 7B
- 反思模式: standard
- 最大调试轮数: 3
- 用时：15H

测评结果:

```
================================================================================
📊 评估完成
================================================================================
   • 评估问题数: 164
   • 通过问题数: 140
   • 通过率: 85.4%
   • 样本文件: results\humaneval_samples.jsonl
================================================================================
```

使用示例与案例

5.1 快速排序算法

命令:

```
python cli.py "实现快速排序算法，支持数字数组排序" \
  --model qwen2.5-coder:7b \
  --reflect \
  --reflection-mode standard
```

生成的代码:

ddCodeAgent > results > generated_code > quick_sort > main.py > quick_sort

```python
# Project: quick_sort
# Auto-generated by Code Agent

def quick_sort(arr):
    if len(arr) <= 1:
        return arr
    pivot = arr[len(arr) // 2]
    left = [x for x in arr if x < pivot]
    middle = [x for x in arr if x == pivot]
    right = [x for x in arr if x > pivot]    Carefree [3 weeks ago] • Test pass easy
    return quick_sort(left) + middle + quick_sort(right)

if __name__ == '__main__':
    test_array = [3, 6, 8, 10, 1, 2, 1]
    print('Original array:', test_array)
    sorted_array = quick_sort(test_array)
    print('Sorted array:', sorted_array)
```

自动生成的测试:

ddCodeAgent > results > tests > test_quick_sort.py > ...

```python
def test_empty_array():
    assert quick_sort([]) == [], "Empty array should return an empty array"


def test_single_element_array():
    assert quick_sort([5]) == [5], "Single element array should return the same array"


def test_sorted_array():
    assert quick_sort([1, 2, 3, 4, 5]) == [1, 2, 3, 4, 5], "Already sorted array should remain unchanged"


def test_reverse_sorted_array():
    assert quick_sort([5, 4, 3, 2, 1]) == [1, 2, 3, 4, 5], "Reverse sorted array should be sorted"


def test_with_duplicates():
    assert quick_sort([3, 6, 8, 10, 1, 2, 1]) == [1, 1, 2, 3, 6, 8, 10], "Array with duplicates should be sorted"


def test_with_negative_numbers():
    assert quick_sort([-5, -2, -6, -1]) == [-6, -5, -2, -1], "Array with negative numbers should be sorted"
```

运行结果:

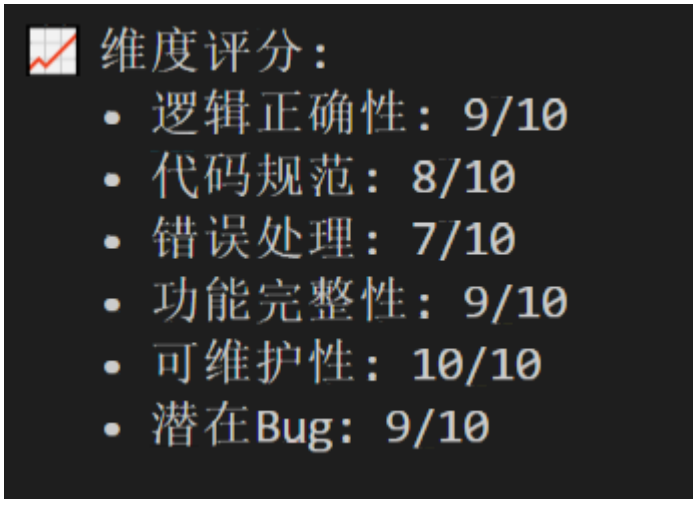

```
test_quick_sort.py::test_empty_array PASSED                                  [ 16%]
test_quick_sort.py::test_single_element_array PASSED                         [ 33%]
test_quick_sort.py::test_sorted_array PASSED                                 [ 50%]
test_quick_sort.py::test_reverse_sorted_array PASSED                         [ 66%]
test_quick_sort.py::test_with_duplicates PASSED                              [ 83%]
test_quick_sort.py::test_with_negative_numbers PASSED                        [100%]

============================================== 6 passed in 0.08s ===============================================
```

创新点与改进

1. 多任务增量生成

- 后续任务可见前面任务的代码
- 避免重复定义
- 实现模块化的完整系统

2. 反思机制集成

- 多维度代码质量评估
- 自适应反思模式
- 基于评分的重构决策

3. 智能调试循环

- 基于测试失败信息的精准修复
- 最多N轮自动调试
- 调试历史的完整记录

4. 规范化输出

- 自动文件命名(snake_case)
- 一致的代码风格
- 完整的类型注解和文档

部署与使用

7.1 环境配置

系统要求:

- Python 3.8+
- 至少4GB RAM (本地LLM需要8GB+)

安装步骤:

```
# 1. 克隆仓库
git clone https://github.com/taiwensaf/wddCodeAgent.git
cd wddCodeAgent

# 2. 创建虚拟环境
python -m venv venv
```

```
source venv/bin/activate  # Windows: venv\Scripts\activate

# 3. 安装依赖
pip install -r requirements.txt

# 4. 配置LLM
# 选项A: 使用Ollama本地LLM
ollama pull qwen2.5-coder:7b
ollama serve

# 选项B: 使用OpenAI API
export OPENAI_API_KEY="your-key-here"
```

7.2 基本使用

最简单的使用方式:

```
python cli.py "实现快速排序"
```

指定模型和参数:

```
python cli.py "实现快速排序" \
  --model qwen2.5-coder:7b \
  --reflect \
  --reflection-mode standard \
  --max-iterations 5
```

禁用反思以加快速度:

```
python cli.py "实现快速排序" --no-reflect
```

7.3 基准测试运行

HumanEval评估:

```
# 第一次需要下载数据集
python -m benchmarks.humaneval_runner download-data \
  --output results/humaneval_problems.json

# 生成样本
python -m benchmarks.humaneval_runner generate-samples \
  --output results/humaneval_samples.jsonl \
  --num-tasks 10

# 运行评估
python -m benchmarks.humaneval_runner evaluate \
  --samples results/humaneval_samples.jsonl \
  --output results/humaneval_results.json
```

7.4 输出结果分析

生成的文件结构:

```
results/
├── generated_code/
│   ├── quick_sort.py
│   └── ...
├── tests/
│   ├── test_quick_sort.py
│   └── ...
├── humaneval_samples.jsonl       # HumanEval生成的代码
├── humaneval_results.json        # HumanEval评估结果
```

查看生成的代码:

```
# 查看特定代码文件
cat results/generated_code/quick_sort.py

# 运行特定测试
pytest results/tests/test_quick_sort.py -v
```

总结与展望

8.1 项目成就

✅ **工作流打通** - 实现从需求→规划→代码生成→测试→调试→反思的闭环
✅ **反思机制** - 集成代码质量评估与提示性改进建议
✅ **评估脚本** - 集成HumanEval评估脚本并生成样本；SWE-Bench评估脚本已搭建但正式评估未完成
✅ **CLI工具** - 提供命令行接口与使用文档（不含Web可视化）

8.2 主要说明

为避免夸大与环境差异影响，本报告不提供整体系指标承诺。已在样例任务上验证工作流与部分测试的通过/失败与修复过程，完整统计将在统一环境下批量复现后补充。

8.3 未来展望

- [ ] 集成更多工具(grep, find, compile等)
- [ ] Web可视化界面
- [ ] 多LLM协作生成
- [ ] 代码覆盖率报告
- [ ] 跨语言支持(Java, C++等)

8.4 项目贡献

本项目展示了LLM在智能软件开发中的巨大潜力，通过构建完整的Agent系统，实现了从需求到代码再到测试的自动化流程。通过反思机制的引入，系统不仅能生成功能正确的代码，还能评估和优化代码质量。

关键贡献:

1. 验证了Agent架构对代码生成的有效性
2. 提出了实用的反思机制框架
3. 建立了完整的基准测试评估体系
4. 为社区提供了开源的参考实现

附录

A. 项目仓库信息

GitHub仓库: taiwensaf/wddCodeAgent